阶跃星辰 Step 3.5 Flash 登顶全球榜单，定义“龙虾时代”的智能体基座范式

在 2026 年初，大模型产业正迈入“龙虾时代”。

竞争的核心，已从参数规模与 Benchmark 排名，转向复杂任务的工程化落地能力与开发者生态的构建效率。

3 月 18 日，阶跃星辰（StepFun）正式确立其新一代战略定位：智能体基座模型。这标志着其从以往偏“项目制交付”的路径，转向面向开发者与复杂系统的通用能力底座提供者。

与此同时，其最新发布的 Step 3.5 Flash 模型，在开源 Agent 项目 OpenClaw 上持续位列全球第一，开始获得海外开发者社区的真实验证与自传播。

如果说上一阶段的大模型竞争是“谁更聪明”，那么这一阶段的分水岭正在变成：谁能在真实世界中，稳定地完成复杂任务。Step 3.5 Flash 能够在 OpenClaw 调用榜上持续位列第一，并非偶然。

其背后的核心原因在于阶跃星辰早在去年底，就已经围绕类似 Agent 形态的产品进行过一轮系统性的工程实践。尽管当时的产品并未形成像 OpenClaw 这样的现象级传播，但其在模型侧已经完成了大量面向 Agent 场景的优化。

因此，当 OpenClaw 作为“爆款载体”出现时，Step 3.5 Flash 实际上是以一种“已经被验证过的工程状态”接入，从而在真实 Agent benchmark 中迅速占据优势。在 Agent 时代，决定模型竞争力的，不只是能力上限，而是工程化后的“可用性密度”。

市场影响：OpenRouter 反响热烈，重塑 Token 性价比极值

“性价比新王”、“Agent 任务的首选主力机”.....在 OpenRouter 开发者社区，Step 3.5 Flash 凭借极致的成本控制与稳定性建立了极佳口碑。阶跃星辰通过极致的工程优化，将 Step 3.5 的推理成本压缩至海外第一梯队某系列的五十分之一。

3 月 OpenRouter LLM Leaderboard 数据显示，Step 3.5 Flash 以 807%的调用量增速位列全榜单第一，单月 Token 调用量已突破 3.44 万亿次。此外，针对活跃用户开放的“每日 1000 条免费 Prompts”计划，进一步加速了其在开发者生态中的渗透。

LLM Leaderboard

Compare the most popular models on OpenRouter

This Month

1.	MiniMax M2.5 by minimax	7.98T tokens ↑304%	
2.	Gemini 3 Flash Preview by google	4.27T tokens ↑45%	
3.	DeepSeek V3.2 by deepseek	3.8T tokens ↑54%	
4.	Step 3.5 Flash (free) by stepfun	3.44T tokens ↑807%	
5.	Claude Opus 4.6 by anthropic	3.24T tokens ↑337%	
6.	Kimi K2.5 by moonshotai	3.13T tokens ↑5%	
7.	Claude Sonnet 4.6 by anthropic	3T tokens new	
8.	Grok 4.1 Fast by x-ai	2.54T tokens ↑57%	
9.	Gemini 2.5 Flash by google	2.25T tokens ↑28%	
10.	Trinity Large Preview (free) by arcee-ai	2.05T tokens ↑117%	

因其强大的 Agent 适配能力，该模型在 3 月 6 日全面开源后，同步登顶 OpenClaw 项目月度总 API 调用率榜。

Top models used by OpenClaw this month

1.	Step 3.5 Flash stepfun	**2.09T** tokens
2.	MiniMax M2.5 minimax	**1.31T** tokens
3.	Trinity Large Preview (free) arcee-ai	**1.02T** tokens
4.	Kimi K2.5 moonshotai	**991B** tokens
5.	Hunter Alpha openrouter	**773B** tokens
6.	Claude Sonnet 4.6 anthropic	**769B** tokens
7.	Gemini 3 Flash Preview google	**708B** tokens
8.	Claude Opus 4.6 anthropic	**601B** tokens

性能实测：极速吞吐与前沿智能的完美融合，专为 Agent 任务而生

在模型性能对标上，阶跃星辰拒绝流于表面的“刷榜”模型，而是聚焦于构建支撑重度 Agent（智能体）任务的坚实工程底座。Step 3.5 Flash 凭借“高智商、低成本、极速响应”组合，重新定义了效率前沿。

1. 峰值 350 TPS 的吞吐量

聊天机器人重在“读”，而智能体必须快在“想”。在 OpenClaw 的实际压力测试下，当国内竞

品在普遍维持在 50 TPS 时，Step 3.5 Flash 常规表现稳定在 100 TPS 以上。在典型场景下吞吐量可达 100－300 TPS，极限单流代码任务峰值更可飙升至 350 TPS。复杂多步骤的推理链也能实现即时响应，让 Agent 的思考过程从“Loading”变为“瞬时完成”，极大提升了交互的丝滑感。

2. 具备自愈机制的长程逻辑一致性：

模型集成了可扩展强化学习框架，在处理万级别 Token 的复杂任务序列时，能从海量信息中精准锁定核心约束。其内置的“状态重构”能力可在毫秒级内找回先前的执行位点，有效解决长周期任务中的记忆衰减问题，确保 Agent 在超长执行链路中始终保持目标对齐。

在模型评测维度，Step 3.5 Flash 展现出横跨智能体调度、复杂工程落地及极限数理推理的全面优势：

· Agent 调度能力：在公认难度极高的 Agent 综合评测 GAIA (no file)中以 84.5 与深度搜索评测 xbench-DeepSearch (2025.05)斩获 83.7，位居榜首。

· 工程能力：在代表动态代码和真实工程解决能力的评测中稳定发挥，LiveCodeBench-V6 达 86.4，SWE-bench Verified 达 74.4，Terminal-Bench 2.0 达 51.0。

· 数理深度：在数学推理黄金标准 AIME 2025 (97.3)与 HMMT 2025 Feb (98.4)中，压制了包括思考模型在内的所有对手。

Benchmark / Model	Activated Params	GAIA(no file)	xbench-DeepSearch (2025.05)	AIME 2025	HMMT 2025 (Feb.)	LiveCodeBench-V6	SWE-bench Verified
Step 3.5 Flash	11B	84.5	83.7	97.3	98.4	86.4	74.4
DeepSeek V3.2	37B	75.1*	78.0*	93.1	92.5	83.3	73.1
Kimi K2 / K2.5	32B	75.6* / 75.9*	76.0* / 76.7*	94.5 / 96.1	89.4 / 95.4	83.1 / 85.0	71.3 / 76.8
GLM-4.7	32B	61.9*	72.0*	95.7	97.1	84.9	73.8
MiniMax M2.1	10B	64.3*	68.7*	83	71.0*	—	74
MiMo-V2 Flash	15B	78.2*	69.3*	94.1 (95.1*)	84.4 (95.4*)	80.6 (81.6*)	73.4

在 2026 年大模型从“参数竞赛”全面转向“工程落地”的关键拐点，阶跃星辰 Step 3.5 Flash 的登场无疑是一场降维打击。当行业仍在长上下文的高昂成本与延迟困局中挣扎时，Step 3.5 Flash 凭借 1.0x 的基准成本与 100+ TPS 的极速响应，彻底终结了高性能、低延迟、低成本之间的“不可能三角”。

Benchmark / Model	Est. decoding cost (128K context)
Step 3.5 Flash	1.0x (100 TPS)
DeepSeek V3.2	6.0x (33 TPS)
Kimi K2 / K2.5	18.9x (33 TPS)
GLM-4.7	18.9x (100 TPS)
MiniMax M2.1	3.9x (100 TPS)
MiMo-V2 Flash	1.2x (100 TPS)

技术突破：MTP-3 并行预测架构与细粒度 MoE 路由

Step 3.5 Flash 的卓越性能，根植于其对“智能体基座”逻辑的底层重构。其核心技术 MTP-3（多 Token 并行预测）与细粒度稀疏混合专家（MoE）路由，夯实了其在高频、重度 Agent 任务中极致能效比的基础。

1. 精益架构：以“举重若轻”实现极致能效比

Step 3.5 Flash 的卓越性能源于对“智能体基座”逻辑的底层重构。其核心采用了细粒度 MoE（混合专家）架构：模型总参数量虽高达 196.81B，但通过自研的智能路由策略，在处理具体任务时仅需调用约 11B 的激活参数。这种“大身躯、轻引擎”的设计，如同在一个拥有数百名顶尖专家的团队中，每次精准指派最合适的 8 位专家协作，确保了模型在保持深度逻辑能力的同时，将推理成本降至行业的“生死线”水平（1.0x 基准成本），彻底解决了 Agent 规模化落地的成本瓶颈。

2. 算法革新：以并行预测与智能记忆实现瞬时响应

针对智能体协作中的延迟痛点，Step 3.5 Flash 引入了 MTP-3（多 Token 并行预测）技术，打破了传统模型“逐字生成”的效率限制。它能够单次预测后续 3-4 个字词，使吞吐量跨越至 100-350 TPS，让 AI 的思考从“加载中”变为“瞬时完成”。同时，配合独创的 3:1 滑动窗口注意力机制（SWA），模型在处理 256K 超长上下文（海量文档或复杂代码库）时，既能保持逻辑的连续性与精准度，又大幅削减了计算开销，为复杂多步骤推理提供了坚实的技术支撑。

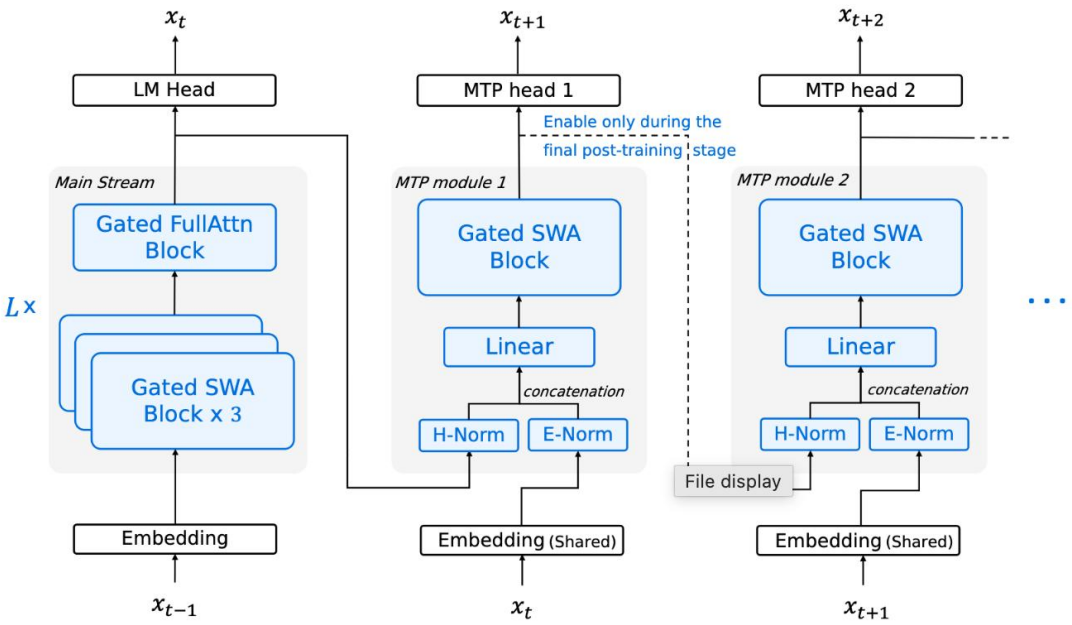

reference：https://static.stepfun.com/blog/step-3.5-flash/
https://github.com/stepfun-ai/Step-3.5-Flash

商业落地实战：深潜垂直行业，打通端到端利润闭环

区别于行业内仅靠底层 API 倒卖的"纸上谈兵",阶跃星辰联动战略合作伙伴千里科技(Qianli)，以"实战派"姿态将 Agent 能力深深扎入高门槛的行业深水区，创造真实的商业价值。

舱驾融合新范式（"超级 Eva"智能体）：在 NVIDIA GTC 2026 大会上，吉利汽车宣布联合阶跃星辰、千里科技打造全球首个整车级智能体"超级 Eva"，并由极氪 8X（Zeekr 8X）量产首发。

依托 Step 3.5 Flash 的"最强龙虾大脑"，利用其单请求最高 350 TPS 的极速推理能力，实现了国内首个类"Grok 上车 Tesla"的原生 AI 体验。

不同于传统"浅层挂载"的聊天机器人，超级 Eva 与智能辅助驾驶（G-ASD 4.0）、底盘、动力等底层系统原生融合。它不仅彻底攻克了车内多人闲聊时系统"乱接话"的行业痛点，更实现了全双工、对话式操控的自然交互。

凭借 Step 3.5 Flash 强大的逻辑规划能力，Eva 能精准理解"接娃放学、顺路订餐、自动找位泊车"等模糊、复杂的长任务指令，真正实现了从"车载语音助手"向"实驾数字生命"的代际跨越。

reference：https://finance.ifeng.com/c/8rZZlADfzC3
https://finance.sina.com.cn/tjhz/2026-03-17/doc-inhrikre5148925.shtml

从垂直应用迈向标准化基座：阶跃星辰的商业升维逻辑

阶跃星辰通过“超级 Eva”在极氪 8X 的成功落地，不仅验证了复杂场景下的工程成熟度，更标志着其战略重心已从定制化交付转向以 Step 3.5 Flash 为核心的标准化 API 供应。阶跃正通过该基座模型打破“性能、延迟、成本”的不可能三角，将车载交互与桌面 Agent“小跃”作为底层能力的实战标杆，实现了跨应用工作流的毫秒级响应。这不仅展示了其技术栈的大规模商业化潜力，更为 2026 年爆发的多智能体协作需求确立了可落地的技术参考与交互标准。

展望未来，阶跃星辰有望通过多端场景工程共生实现技术低成本复用；强化学习数据飞轮积累真实任务轨迹，以及驱动持续进化以及极致能效比以成本优势绑定开发者生态锚定竞争优势，确保在 AGI 时代的长期主导权。