被投企业动态丨阶跃星辰 Step 3.5 Flash 登顶全球榜单，定义“智能体基座”时代的实干范式

在 2026 年大模型进入“Agent 爆发元年”的今天，行业竞争已从单纯的参数竞赛转向了复杂的工程落地与生态构建。

3 月 18 日，阶跃星辰（StepFun）披露了其最新的战略转向：正式确立 Agent Foundation Model（智能体基座模型）为核心定位。这意味着阶跃正从传统的定制化交付模式，彻底转向“能力与生态”驱动的基础设施供应商。此前，其新一代基座模型 Step 3.5 Flash 已在知名开源项目 OpenClaw（“小龙虾”）上连续多日位居全球第一，引发海外开发者社区的高度关注。

阶跃星辰正以一种极其务实的“工程哲学”，在 AGI 时代的落地大潮中扮演起支撑重度任务的“高性能生产力引擎”。

市场影响：OpenRouter 反响热烈，重塑 Token 性价比极值

“性价比新王”、“Agent 任务的首选主力机”.....在 OpenRouter 开发者社区，Step 3.5 Flash 凭借极致的成本控制与稳定性建立了极佳口碑。阶跃星辰通过极致的工程优化，将 Step 3.5 的推理成本压缩至 GPT 系列的五十分之一。

3 月 OpenRouter LLM Leaderboard 数据显示，Step 3.5 Flash 以 807% 的调用量增速位列全榜单第一，单月 Token 调用量已突破 3.44 万亿次。此外，针对活跃用户开放的“每日 1000 条免费 Prompts”计划，进一步加速了其在开发者生态中的渗透。

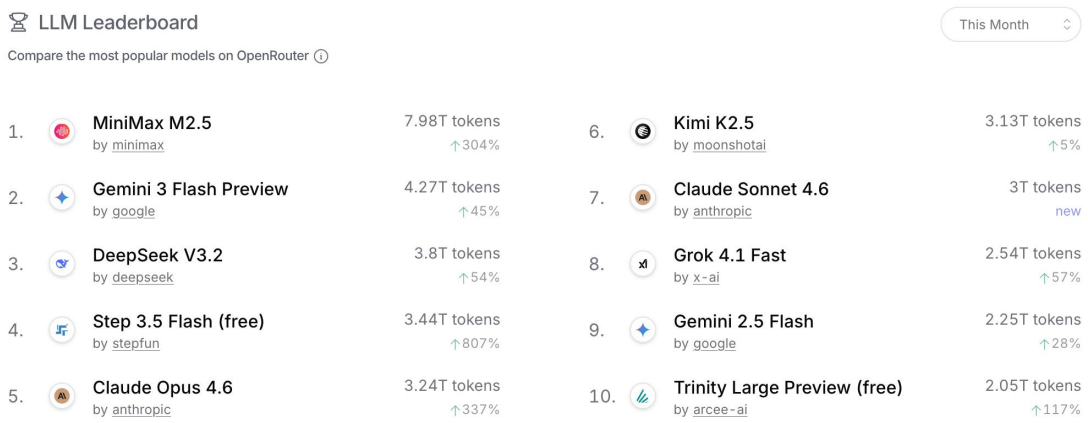

因其强大的 Agent 适配能力，该模型在 3 月 6 日全面开源后，同步登顶 OpenClaw 项目月度总 API 调用率榜。

Top models used by OpenClaw this month

1.	Step 3.5 Flash stepfun	**2.09T** tokens
2.	MiniMax M2.5 minimax	**1.31T** tokens
3.	Trinity Large Preview (free) arcee-ai	**1.02T** tokens
4.	Kimi K2.5 moonshotai	**991B** tokens
5.	Hunter Alpha openrouter	**773B** tokens
6.	Claude Sonnet 4.6 anthropic	**769B** tokens
7.	Gemini 3 Flash Preview google	**708B** tokens
8.	Claude Opus 4.6 anthropic	**601B** tokens

性能实测：极速吞吐与前沿智能的完美融合，专为 Agent 任务而生

在模型性能对标上，阶跃星辰拒绝流于表面的“刷榜”模型，而是聚焦于构建支撑重度 Agent（智能体）任务的坚实工程底座。Step 3.5 Flash 凭借“高智商、低成本、极速响应”组合，重新定义了效率前沿。

1. 峰值 350 TPS 的吞吐量

聊天机器人重在“读”，而智能体必须快在“想”。在 OpenClaw 的实际压力测试下，当国内竞品在普遍维持在 50 TPS 时，Step 3.5 Flash 常规表现稳定在 100 TPS 以上。在典型场景下吞吐量可达 100－300 TPS，极限单流代码任务峰值更可飙升至 350 TPS。复杂多步骤的推理链也能实现即时响应，让 Agent 的思考过程从“Loading”变为“瞬时完成”，极大提升了交互的丝滑感。

2. 具备自愈机制的长程逻辑一致性：

模型集成了可扩展强化学习框架，在处理万级别 Token 的复杂任务序列时，能从海量信息中精准锁定核心约束。其内置的“状态重构”能力可在毫秒级内找回先前的执行位点，有效解决长周期任务中的记忆衰减问题，确保 Agent 在超长执行链路中始终保持目标对齐。

在模型评测维度，Step 3.5 Flash 展现出横跨智能体调度、复杂工程落地及极限数理推理的全

面优势：

· Agent 调度能力：在公认难度极高的 Agent 综合评测 GAIA (no file)中以 84.5 与深度搜索评测 xbench-DeepSearch (2025.05)斩获 83.7，位居榜首。

· 工程能力：在代表动态代码和真实工程解决能力的评测中稳定发挥，LiveCodeBench-V6 达 86.4，SWE-bench Verified 达 74.4，Terminal-Bench 2.0 达 51.0。

· 数理深度：在数学推理黄金标准 AIME 2025 (97.3)与 HMMT 2025 Feb (98.4)中，压制了包括思考模型在内的所有对手。

Benchmark / Model	Activated Params	GAIA(no file)	xbench-DeepSearch (2025.05)	AIME 2025	HMMT 2025 (Feb.)	LiveCodeBench-V6	SWE-bench Verified
Step 3.5 Flash	11B	84.5	83.7	97.3	98.4	86.4	74.4
DeepSeek V3.2	37B	75.1*	78.0*	93.1	92.5	83.3	73.1
Kimi K2 / K2.5	32B	75.6* / 75.9*	76.0* / 76.7*	94.5 / 96.1	89.4 / 95.4	83.1 / 85.0	71.3 / 76.8
GLM-4.7	32B	61.9*	72.0*	95.7	97.1	84.9	73.8
MiniMax M2.1	10B	64.3*	68.7*	83	71.0*	—	74
MiMo-V2 Flash	15B	78.2*	69.3*	94.1 (95.1*)	84.4 (95.4*)	80.6 (81.6*)	73.4

在 2026 年大模型从“参数竞赛”全面转向“工程落地”的关键拐点，阶跃星辰 Step 3.5 Flash 的登场无疑是一场降维打击。当行业仍在长上下文的高昂成本与延迟困局中挣扎时，Step 3.5 凭借 1.0x 的基准成本与 100+ TPS 的极速响应，彻底终结了高性能、低延迟、低成本之间的“不可能三角”。

Benchmark / Model	Est. decoding cost (128K context)
Step 3.5 Flash	1.0x (100 TPS)
DeepSeek V3.2	6.0x (33 TPS)
Kimi K2 / K2.5	18.9x (33 TPS)
GLM-4.7	18.9x (100 TPS)
MiniMax M2.1	3.9x (100 TPS)
MiMo-V2 Flash	1.2x (100 TPS)

技术突破：MTP-3 并行预测架构与细粒度 MoE 路由

Step 3.5 Flash 的卓越性能，根植于其对“智能体基座”逻辑的底层重构。其核心技术 MTP-3

（多 Token 并行预测）与细粒度稀疏混合专家（MoE）路由，夯实了其在高频、重度 Agent 任务中极致能效比的基础。

1. 11B 激活参数与细粒度 MoE

推理成本是衡量 Agent 规模化落地的“生死线”。Step 3.5 Flash 实现了 1.0x 的基准解码成本，这一数据在面对同类模型动辄 6 倍、甚至 8 倍的成本压力时，展现出了极致的竞争优势。实现这一突破的关键，在于阶跃星辰精妙的底层架构设计：

模型总参数量高达 196.81B（由 196B 骨干网络与 0.81B Head 组成），确保了模型具备处理复杂逻辑和海量知识的基础。

通过自研的细粒度路由策略，Step 3.5 在每层配置了 1 个共享专家与高达 288 个路由专家。在推理执行阶段，每 Token 仅激活 Top-8 专家，使得每次生成仅需调动 ~11B 激活参数。这种“举重若轻”的架构，让 Step 3.5 Flash 在不折损智能深度的前提下，实现了对计算资源近乎严苛的节省。

2. MTP-3 算法：吞吐量极致提升

在智能体协作场景中，响应速度直接决定了任务链的成败。M1 依靠算法提效，而 Step 3.5 Flash 则通过 MTP-3（Multi-Token Prediction）打破了传统自回归模型逐字生成的效率瓶颈。

Step 3.5 Flash 配备了包含滑动窗口注意力和稠密前馈网络（FFN）的专属 MTP Head。不同于传统的逐字预测，它能够在单次前向传播中同时预测后续 3-4 个 Token。

这一创新让 Step 3.5 Flash 实现了 100-350 TPS 的性能跨越，将 Agent 的思考过程从“Loading 状态”直接拉入“瞬时完成”时代，为复杂多步骤推理提供了即时响应的可能。

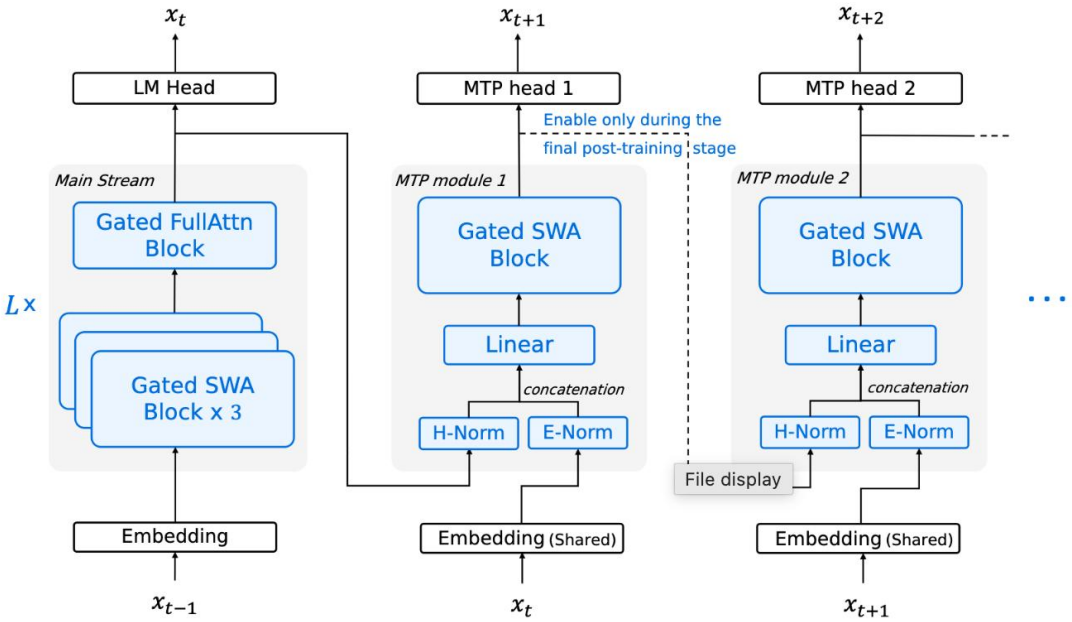

3. 3:1 SWA 混合机制：高能效比的 256K 长上下文

处理超长代码库或海量文档是 Agent 的核心工况。Step 3.5 Flash 原生支持 256K 上下文窗口，并引入了独创的 3:1 滑动窗口注意力（SWA）比例。

模型采用“1 层全注意力 + 3 层滑动窗口注意力”的混合循环机制。这种设计大幅削减了长文本处理时的计算开销与显存占用。

在处理超长上下文时，Step 3.5 Flash 依然能保持性能不减，确保了在深度搜索与复杂工程解决场景下的逻辑连续性。

厂商/模型	核心架构支撑	架构功能
Step 3.5 Flash	MTP-3 + MoE (11B Active)	低延迟执行：3 倍预测技术让 Agent 思考过程几乎瞬时完成。
MiniMax M2.5	Lightning Attention	长文本稳健：适合处理长达 200k 的文档搜索与数据提取。
DeepSeek V3.2	MLA + DeepSeekMoE + DSA (稀疏注意力)	高性价比长文本与智能体：凭借 MLA 与 DSA 架构大幅降低推理成本；首个支持“思考融入工具调用”的开源模型。
Kimi K2.5	Agent Swarm (蜂群/集群架构)	复杂规划：擅长将大任务拆解给子智能体执行。
智谱 GLM-4.7	GLM 原生架构 + All-Tools 引擎	全场景智能体：原生支持代码解释器、网页浏览与多工具无缝协同，适合综合性复杂任务。

reference：https://static.stepfun.com/blog/step-3.5-flash/
https://github.com/stepfun-ai/Step-3.5-Flash

商业落地实战：深潜垂直行业，打通端到端利润闭环

区别于行业内仅靠底层 API 倒卖的“纸上谈兵”，阶跃星辰联动战略合作伙伴千里科技（Qianli），以“实战派”姿态将 Agent 能力深深扎入高门槛的行业深水区，创造真实的商业价值。

舱驾融合新范式（“超级 Eva”智能体）：在 NVIDIA GTC 2026 大会上，吉利汽车宣布联合阶跃星辰、千里科技打造全球首个整车级智能体“超级 Eva”，并由极氪 8X（Zeekr 8X）量产首发。

依托 Step 3.5 Flash 的“最强龙虾大脑”，利用其单请求最高 350 TPS 的极速推理能力，实现了国内首个类“Grok 上车 Tesla”的原生 AI 体验。

不同于传统“浅层挂载”的聊天机器人，超级 Eva 与智能辅助驾驶（G-ASD 4.0）、底盘、动

力等底层系统原生融合。它不仅彻底攻克了车内多人闲聊时系统“乱接话”的行业痛点，更实现了全双工、对话式操控的自然交互。

凭借 Step 3.5 强大的逻辑规划能力，Eva 能精准理解“接娃放学、顺路订餐、自动找位泊车”等模糊、复杂的长任务指令，真正实现了从“车载语音助手”向“实驾数字生命”的代际跨越。

reference：https://finance.ifeng.com/c/8rZZlADfzC3
https://finance.sina.com.cn/tjhz/2026-03-17/doc-inhrikre5148925.shtml

从垂直应用迈向标准化基座：阶跃星辰的商业升维逻辑

极氪 8X 搭载“超级 Eva”的成功落地，不仅验证了阶跃星辰在复杂场景下的工程能力，更标志着其技术栈已具备大规模商业化的成熟度。在 2026 年多智能体（Multi-Agent）协作需求爆发的背景下，阶跃星辰的战略重心已发生显著偏移。

阶跃星辰正通过 Step 3.5 Flash 试图打破长期困扰行业的“性能、延迟、成本”不可能三角。其核心商业逻辑已从早期的定制化项目交付，转向标准化的 API 基础设施供应。车载交互系统不再是单一的业务终点，而是作为底层能力的“实战验证”。

面对多智能体协同办公、工业级自动化调度等高频推理场景，Step 3.5 Flash 凭借 1.0x 的基准成本控制与峰值为 350 TPS 的高吞吐性能，有效解决了 Agent 集群大规模部署时的算力成本瓶颈。通过从“垂直方案商”向“基础设施底座”的定位切换，阶跃星辰正在建立一种以 API 规模化调用为核心的利润模型，为 2026 年的智能体生态提供标准化的性能支撑。